


# **LIBRO DE RESÚMENES DEL XXIII CONGRESO ARGENTINO DE BIOINGENIERÍA Y XII JORNADAS DE INGENIERÍA CLÍNICA**

**SAN JUAN, ARGENTINA  
SEPTIEMBRE DE 2022**



## **SABI 2022**

### **SAN JUAN**

Sociedad Argentina de Bioingeniería

Libro de Resúmenes del XXIII Congreso Argentino de Bioingeniería y XII Jornadas de Ingeniería Clínica : San Juan, Argentina : Septiembre de 2022 / compilación de Kyomi Shiratori Cañadas ; Valentina Morales ; editado por Natalia Martina Lopez. - 1a ed. - Tucumán : Sociedad Argentina de Bioingeniería, 2022.

Libro digital, PDF

ISBN 978-987-27301-1-6



Simulation of single fiber action potentials in a cylindrical EMG model: a comparative study	115
Knee prostheses modelling: deformation of the low rigidity component	116
Potential effects of physical activity during menopause according to a computational model of bone remodeling applied to the femur	117
Parametric analysis of a polymeric aortic valve prosthesis: structural study for non- basal loading.	118
Numerical simulation of a ventricular diastolic filling	119
PROCESAMIENTO DE IMÁGENES	120
AI-based descriptors of the distribution of SARS-CoV-2 in chest CT-scans	121
Pneumonia classification and analysis in Chest X-ray by means of Convolutional Neural Networks	122
Anatomical Localization of Effective ConnectivityMap Applied to Epilepsy Treatment.	123
Metrics applied to brain neural networks	124
Evaluation of segmentation tools applied to epilepsy	125
Leukocyte segmentation using morphological reconstruction defined in a fuzzy color space	126
Convolutional Neural Networks and feature-visualization for pathology classification in Mammograms	127
Non-invasive intraventricular pressure differences estimated with 4D-Flow cardiac MRI	128
Ascending and Descending Aorta SegmentationUsing Convolutional Neural Networks in Non- Contrast CT Images	129
App development for measuring seminal quality of bovine sperm <i>in situ</i>	130
In Vivo obtention and representation of Muscle'sPaths from Magnetic Resonance Images	131
Computation of Scores by Pattern Recognition In Lung Ultrasound Videos	132
Eye-movement–based assessment of cognitive and neuropsychological disorders	133
Infrared image processing software for early detection of lower limbs sports injuries	134
Post-processing of medical image for neurosurgical planning with academic purposes	135
Application of image and video processing techniques to eye fundus with retinopathy of prematurity acquired from a smartphone	
Determinación de la Carga Microbiana en Agua por Medio del Análisis de Patrones de Speckle Dinámico	137
PROCESAMIENTO DE SEÑALES BIOMÉDICAS	138
An effective connectivity model based on excitation-inhibition imbalance to classify states of the epileptogenic network	139
EEG Analysis of Pediatric Pleasure and Unpleasure Emotions	140
Feature Extraction with Wavelets for Plethysmography Signal Classification	141

## PROCESAMIENTO DE IMÁGENES



# AI-based descriptors of the distribution of SARS-CoV-2 in chest CT-scans

Milagros N. Ledesma, Javier Cebeiro, Marcela Morvidone

*Centro de Matemática Aplicada (CEDEMA), Instituto de Tecnologías Emergentes y Ciencias Aplicadas (ITECA), UNSAM-CONICET, Escuela de Ciencia y Tecnología: San Martín, Buenos Aires, Argentina.*

---

**Abstract**— In this work we propose descriptors for the study of the distribution and extension of the SARS- CoV-2 pneumonia in chest CT scans. The aim is to characterize distinctive radiological findings of the syndrome by means of descriptors derived from detection and segmentation AI-algorithms. The analysis allowed to find representative patterns of the distribution of the infection in the lung. It also suggests that descriptors derived from segmentation algorithms can be replaced by others based on classification algorithms that are easier to develop. This opens future lines of research for SARS-CoV-2 and other pathologies that are studied through images.

**Keywords**— SARS-CoV-2, artificial intelligence, deep learning, CT-scans.

---

**Resumen**— En este trabajo proponemos descriptores para el estudio de la distribución y extensión de la neumonía asociada al SARS-CoV-2 en imágenes de tomografía de tórax. El objetivo es caracterizar los hallazgos radiológicos distintivos del síndrome por medio de descriptores obtenidos a partir de algoritmos de detección y segmentación basados en inteligencia artificial. El análisis permitió hallar patrones característicos de la distribución de la infección en el pulmón. También sugiere que los descriptores derivados de algoritmos de segmentación pueden ser sustituidos por otros basados en algoritmos de clasificación que son más fáciles de desarrollar. Esto abre líneas futuras de investigación tanto para el caso del SARS-CoV-2 como de otras patologías que se estudian por imágenes.

**Palabras clave**— SARS-CoV-2, inteligencia artificial, aprendizaje profundo, imágenes tomográficas.

# AI-based characterization of SARS-CoV-2 pneumonia in chest CT scans

Milagros N. Ledesma, Javier Cebeiro, Marcela Morvidone

Contacto: Javier Cebeiro, Centro de Matemática Aplicada (CEDEMA), Instituto de Tecnologías Emergentes y Ciencias Aplicadas (ITECA), UNSAM-CONICET, Escuela de Ciencia y Tecnología: San Martín, Buenos Aires, Argentina, [jcebeiro@unsam.edu.ar](mailto:jcebeiro@unsam.edu.ar).

**Abstract—** In this work we present a systematic methodology for the study of the distribution of the characteristic lesions of pneumonia caused by SARS-CoV-2 in chest tomography images. The study is based on metrics derived from functions that represent the distribution of characteristic lesions in different anatomical regions of the lung. These metrics are derived from AI-based detection and segmentation algorithms. The systematic analysis allowed us to determine some characteristic patterns of the distribution of the infection and suggests possible future lines of study.

**Keywords—** SARS-CoV-2, artificial intelligence, deep learning, CT scans.

**Resumen—** En este trabajo presentamos una metodología para el estudio de la distribución y extensión de la neumonía asociada al SARS-CoV-2 en imágenes de tomografía de tórax. El estudio se basa en descriptores que cuantifican la distribución de las lesiones características del síndrome. Los descriptores se obtienen a partir de algoritmos de detección y segmentación basados en inteligencia artificial. El análisis sistemático permitió determinar algunos patrones característicos de la distribución de la infección en el pulmón y sugiere posibles líneas futuras de estudio.

**Palabras clave—** SARS-CoV-2, inteligencia artificial, aprendizaje profundo, imágenes tomográficas.

## I. INTRODUCCIÓN

LA irrupción inesperada de la pandemia COVID-19 representó una grave amenaza para la humanidad. La infección generada por el coronavirus de tipo 2 produce una variedad de síntomas, algunos potencialmente mortales, entre los que se encuentran los correspondientes al síndrome respiratorio agudo severo conocido como SARS-CoV-2. Los hallazgos principales en las imágenes tomográficas de tórax de los afectados incluyen parches con opacidades del tipo vidrio esmerilado que afectan en general varios lóbulos, o incluso ambos pulmones, y son de predominio periférico. Otros hallazgos son la presencia de derrame pleural y la tendencia a la consolidación. La figura 1 compara un corte tomográfico de un sujeto normal y otro que presenta SARS-CoV-2 y la figura 2(a) muestra dos sujetos, uno con lesiones de predominio derecho y otro, izquierdo. Durante la pandemia COVID-19 hubo numerosos intentos de abordar los problemas de clasificación, segmentación y cuantificación de imágenes radiológicas, muchos de los cuales se describen en [1], [2]. En este trabajo presentamos una metodología sistemática para el estudio de la distribución de las lesiones características de la neumonía asociada al SARS-CoV-2 en tomografías de tórax. El estudio se basa en cuantificadores que miden la distribución de una determinada lesión en distintas regiones del pulmón. Estos descriptores derivan de funciones que se obtienen con algoritmos de detección y segmentación basados en inteligencia artificial.






Fig. 1. Sujeto normal (izq) y otro con SARS-CoV-2 (der).

## II. MATERIALES Y MÉTODOS


Para el estudio de la distribución de los hallazgos característicos de la neumonía asociada al SARS-CoV-2 se desarrolló un clasificador basado en una red neuronal que luego se utilizará en un *pipeline* de procesamiento que incluye algoritmos de segmentación desarrollados por otros grupos, operaciones morfológicas y el cálculo de descriptores. Una vez clasificadas, las imágenes pasan a una segunda etapa donde se segmentarán los pulmones izquierdo y derecho, los cinco lóbulos, cuatro subregiones pulmonares y tres tipos de lesiones distintivas del SARS-CoV-2. Finalmente se calculan los descriptores y se hace el análisis de los patrones dominantes. A continuación se describen las etapas fundamentales.



(a) Sujetos con afectación predominante derecha e izquierda. .



(b) Segmentación de lesiones tipo 1 (rojo) y tipo 2 (verde) .



(c) Heatmap del clasificador superpuesto a la imagen original .

Fig. 2. Paciente con predominio derecho.

### A. Base de datos

Se utilizaron volúmenes tomográficos con aproximadamente 150 cortes cada uno, correspondientes a 108 sujetos (54 normales y 54 con diagnóstico confirmado de SARS-CoV-2). Las imágenes provienen de una base de datos pública, extensivamente documentada, donde cada corte identificado como positivo fue anotado por un comité de médicos especialistas en diagnóstico por imágenes con varios años de experiencia [3]. Cada imagen tenía  $512 \times 512$  píxeles.

### B. Clasificador

Para la clasificación binaria de cortes individuales se utilizó una red neuronal con una arquitectura DenseNet221 y función de activación sigmoidea con más de siete millones de parámetros ajustables. La elección se debe a que esta configuración demostró un desempeño adecuado en problemas de clasificación multiclase de Rx de tórax [4]. Para el desarrollo se utilizó un total de 7459 imágenes en los siguientes conjuntos: entrenamiento (5318, 50% de positivos), validación (1486, 48% de positivos) y testeo (755, 53 % de positivos), sin superposición de pacientes ni imágenes entre los

conjuntos. Cada volumen tomográfico estaba conformado por alrededor de 150 cortes. En los casos normales estos fueron seleccionados con muestro uniforme con igual predominio de cortes superiores, centrales e inferiores. En los casos positivos hubo mayor predominio de imágenes de la región central del pulmón (histograma con aspecto gaussiano). El entrenamiento se realizó con una GPU NVIDIA GeForce GTX 1650 Ti empleando la *crossentropy* como función de pérdida y un optimizador del tipo Adam. Se utilizaron 20 etapas de entrenamiento con corte cuando la tasa de aprendizaje disminuyó al 10% de la inicial. Se complementó con un algoritmo GradCam para obtener los *heatmaps*, mapas de activación de la red neuronal, que señalan las regiones de la imagen que tienen un rol preponderante en la activación de la salida [5], [6]. Las figuras 2(c) muestran ejemplos de estos *heatmaps* superpuestos con la imagen de origen. Observar que las zonas de mayor probabilidad coinciden con las de los detalles radiológicos más visibles.

### C. Segmentación y subsegmentación del pulmón y las lesiones

Para cada corte se generaron máscaras de segmentación a partir del algoritmo disponible en [7]. Dicho algoritmo se basa en una red neuronal con arquitectura U-net descrita en [8]. Las máscaras generadas son: pulmón derecho e izquierdo, lóbulo inferior derecho, lóbulo medio derecho, lóbulo superior derecho, lóbulo inferior izquierdo y lóbulo superior izquierdo. Independientemente, cada máscara de pulmón izquierdo y derecho fue subsegmentada en cuatro regiones que corresponden a un cuarto del área total de la máscara del pulmón. Estas se llaman cuarto interno, cuarto medial interno, cuarto medial externo y cuarto externo, ver figura 3. Esta subsegmentación es arbitraria y fue propuesta a los fines de este trabajo. El cuarto externo se obtuvo mediante la erosión de la máscara pulmonar con un kernel de  $3 \times 3$  píxeles hasta alcanzar un 75% del área inicial y sustrayendo la máscara erosionada a la máscara original. El resto de los cuartos se obtuvo de manera análoga llegando al 50 y 25 % del área inicial según corresponda. Para la segmentación de lesiones se utilizó la herramienta disponible en la web que realiza la segmentación en tres tipos de lesiones: opacidades, consolidación y derrame pleural (tipo 1, 2, y 3 respectivamente) [9]. Ejemplos de estas máscaras se pueden ver en las figuras 2(b). Notar la correspondencia entre máscaras de lesiones y la posición de los signos radiológicos más distintivos en la figura 2(a).

### D. Descriptores de la distribución de los hallazgos radiológicos

Se utilizarán varios descriptores para la cuantificación de la distribución y extensión de los signos característicos de SARS-CoV-2. Estos cuantifican el grado afectación de una región pulmonar dada y se basan en el producto escalar entre funciones. Para funciones reales de soporte compacto en  $\mathbb{R}^2$ , el producto escalar  $q_{AB}$  se define como

$$q_{AB} = \langle f_A, g_B \rangle = \int_{\mathbb{R}^2} d\mathbf{x} f_A(\mathbf{x}) g_B(\mathbf{x}), \quad (1)$$

Si la segunda función es  $g_B(\mathbf{x}) = \mathbb{1}_B(\mathbf{x})$ , es decir la función característica del conjunto  $B$ <sup>1</sup>, la cantidad  $q_{AB}$  es la integral

<sup>1</sup>La función característica del conjunto  $B$  se define  $\mathbb{1}_B(\mathbf{x}) = 1$  si  $\mathbf{x} \in B$  o  $\mathbb{1}_B(\mathbf{x}) = 0$  en caso contrario.

de la función  $f_A$  en el subconjunto  $B$ . En el caso particular en que  $f_A$  sea una función característica en el conjunto  $A$ , entonces la cantidad  $q_{AB}$  será el área de la intersección de los dos conjuntos. Para nuestro caso el conjunto  $B$  podrá ser uno de los pulmones, uno de los cinco lóbulos o uno de los cuartos descriptos en la sección II-C. La función  $f_A$  podrá ser o bien el mapa de activación del corte (*heatmap*) o una de las máscaras de cada tipo de lesión. Así, cuando  $f_A$  sea el *heatmap* de la activación y  $B$  sea el cuarto externo del pulmón derecho, la cantidad  $q_{AB}$  representa la integral del *heatmap* en la región periférica del pulmón derecho. Asimismo, cuando  $f_A$  sea la suma de las máscaras de las opacidades y consolidación (lesión tipo 1 y tipo 2) y  $B$  sea el lóbulo inferior derecho, la cantidad  $q_{AB}$  será el área en el lóbulo inferior derecho que presenta opacidades y consolidación. Los descriptores se utilizarán para clasificar las imágenes de acuerdo al predominio de las lesiones: pulmón dominante (izquierdo, derecho, bilateral o sin lesiones), lóbulo dominante y cuarto dominante. Para cada caso, una imagen pertenece a una única categoría. La imagen se clasifica como libre cuando no presenta lesiones. Para el caso del predominio pulmonar, este es bilateral cuando la diferencia entre los cuantificadores laterales es menor al 5% de la suma de ambos. Para cada caso, la función  $f_A$  consiste o bien en las lesiones segmentadas con la herramienta [9] o bien en el *heatmap* de la red neuronal.

### III. RESULTADOS

Luego del entrenamiento, se evaluó la red neuronal en el conjunto de testeo presentando 399 verdaderos positivos, 284 verdaderos negativos, 4 falsos positivos y 65 falsos negativos. La sensibilidad fue de 0.86, la especificidad fue de 0.99, la exactitud (*accuracy*) fue de 0.91 y tasa de error en la clasificación 0.09 (*misclassification rate*). La figura 5 muestra las curvas ROC y PR en el conjunto de testeo, el modelo presentó una  $AUC = 0.99$ . Para el estudio de las distribución de las lesiones se utilizaron las imágenes anotadas como positivas en la base de datos. Se realizó la segmentación y subsegmentación, se obtuvo el *heatmap* y se calcularon los descriptores y se los comparó a todos los niveles, i.e. pulmón, lóbulos y cuartos. Para calcular los descriptores basados en las lesiones se utilizó la suma de las máscaras tipo 1 y tipo 2 (opacidades y consolidación) ya que no se detectó la presencia de lesiones tipo 3 (derrame pleural) en ningún caso. La figura 4 muestra resultados a nivel del pulmón, lóbulos y cuartos pulmonares. En cada caso se muestra la cantidad de cortes donde predomina cada clase utilizando los descriptores basados en las lesiones o el *heatmap*. Así, la figura 4(b) muestra que el lóbulo inferior derecho es el más afectado en la mayoría de los cortes seguido del lóbulo inferior izquierdo. Los lóbulos superiores le siguen y finalmente el lóbulo medio es menos afectado. La similitud entre los resultados del *heatmap* y la segmentación de lesiones sugieren la utilidad del estudio del problema de clasificación multiclase basada en el *heatmap* y tomando como *groundtruth* la clasificación en base a las lesiones. Esto se realizó para los cortes individuales y para el volumen total, la figura V muestra las matrices de confusión y las métricas.

### IV. DISCUSIÓN

Los gráficos sugieren un leve predominio del pulmón derecho (figura 4(a)) y que los lóbulos inferiores se ven más afectados que los superiores (figura 4(b)). Ambos efectos se observan tanto con descriptores derivados del *heatmap* como derivados de la segmentación de lesiones. Las regiones periféricas del pulmón exhiben mayor afectación que las internas (figura 4(c)). El predominio derecho puede deberse a una característica de la base de datos utilizada o a que el pulmón derecho es más grande (mayor área por corte y mayor volumen total). En un próximo desarrollo se incluirá un factor de ponderación para compensar este efecto. Los cuartos pulmonares no presentan este sesgo ya que son regiones autonormalizadas (todas presentan la misma área). Es por eso que se eligió subsegmentar en una región anatómica arbitraria.

Para las clasificación de los pulmones y lóbulos más afectados se calculó la matriz de confusión. Para cortes individuales de obtuvo un desempeño de alrededor del 80%. Para el volumen total el desempeño mejora casi hasta un 90%. Esto sugiere que los descriptores derivados de la segmentación de lesiones podrían sustituirse por los derivados del *heatmap*. Esto es importante ya que la segmentación de lesiones exige una ardua tarea de preparación manual de las máscaras para el entrenamiento mientras que el *heatmap* deriva de una clasificación binaria de cada corte. La concordancia sugiere además un buen desempeño del clasificador ya que fueron entrenadas con bases de datos diferentes. Existen recomendaciones de realizar el entrenamiento con múltiples bases de datos y otras listas de verificación a tener en cuenta [10]. Con respecto a la cantidad de sujetos involucrados en el estudio, es necesario realizar más trabajo [11].

### V. CONCLUSIONES

La metodología resultó adecuada para identificar las características conocidas del SARS-CoV-2: predominio periférico e inferior. Los resultados sugieren que el *heatmap* podría reemplazar la segmentación de lesiones. Es necesario, no obstante, incluir las recomendaciones en [2], [10], [11] en cuanto al desarrollo de algoritmos de inteligencia artificial. Otras combinaciones de descriptores pueden ser ideadas.

### AGRADECIMIENTOS

M.L. realizó sus tareas de investigación en el marco de una beca del Programa Estratégico de Formación de Ingenieros de la Escuela de Ciencia y Tecnología de la ECyT-UNSAM. J.C. y M.M. reciben financiamiento parcial del fondo SOARD-AFOSR (grant number FA9550-18-1-0523).

### REFERENCIAS

- [1] F. Shi, J. Wang *et al.*, "Review of artificial intelligence techniques in imaging data acquisition, segmentation, and diagnosis for covid-19," *IEEE Reviews in Biomedical Engineering*, vol. 14, pp. 4–15, 2021.
- [2] M. Roberts, D. Driggs *et al.*, "Common pitfalls and recommendations for using machine learning to detect and prognosticate for covid-19 using chest radiographs and ct scans," *Nature Machine Intelligence*, vol. 3, no. 3, pp. 199–217, Mar 2021. [Online]. Available: <https://doi.org/10.1038/s42256-021-00307-0>
- [3] P. Afshar, S. Heidarian *et al.*, "Covid-ct-md, covid-19 computed tomography scan dataset applicable in machine learning and deep learning," *Scientific Data*, vol. 8, no. 1, p. 121, Apr 2021. [Online]. Available: <https://doi.org/10.1038/s41597-021-00900-3>







Fig. 3. Segmentación de lóbulos a) axial, b) coronal (rojo: inferior derecho, naranja: medio derecho, amarillo: superior derecho, verde: inferior izquierdo, azul: superior izquierdo). c) Pulmón izquierdo (rojo) y derecho (verde). d) Cuartos (azul: externo, verde: medial externo, naranja: medial interno, rojo: interno).



(a) Pulmón dominante .



(b) Lóbulo dominante .



(c) Cuarto dominante .

Fig. 4. Distribución de las señales en cada categoría.






Fig. 5. Desempeño del clasificador.



(a) Clasificación pulmón dominante (b) Clasificación lóbulo dominante por corte (*accuracy* = 0.81).



(c) Clasificación pulmón dominante (d) Áreas relativas de los cuartos y sus por volumen total *accuracy* = 0.87. desvíos.

- [4] P. Rajpurkar, J. Irvin *et al.*, "Deep learning for chest radiograph diagnosis: A retrospective comparison of the chexnext algorithm to practicing radiologists," *PLOS Medicine*, vol. 15, no. 11, pp. 1–17, 11 2018. [Online]. Available: <https://doi.org/10.1371/journal.pmed.1002686>
- [5] R. R. Selvaraju, M. Cogswell *et al.*, "Grad-cam: Visual explanations from deep networks via gradient-based localization," in *2017 IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 618–626.
- [6] —, "Grad-cam: Visual explanations from deep networks via gradient-based localization," *International Journal of Computer Vision*, vol. 128, no. 2, pp. 336–359, Feb 2020. [Online]. Available: <https://doi.org/10.1007/s11263-019-01228-7>
- [7] "Lungmask," <https://github.com/JoHof/lungmask>, accessed: 2022-29-05.
- [8] J. Hofmanninger, F. Prayer *et al.*, "Automatic lung segmentation in routine imaging is primarily a data diversity problem, not a methodology problem," *European Radiology Experimental*, vol. 4, no. 1, p. 50, Aug 2020. [Online]. Available: <https://doi.org/10.1186/s41747-020-00173-2>
- [9] "Medicalsegmentation," <http://htmlsegmentation.s3.eu-north-1.amazonaws.com/index.html>, accessed: 2022-29-05.
- [10] J. Mongan, L. Moy, and C. E. Kahn, "Checklist for artificial intelligence in medical imaging (claim): A guide for authors and reviewers,"

- Radiology: Artificial Intelligence*, vol. 2, no. 2, p. e200029, 2020, PMID: 33937821. [Online]. Available: <https://doi.org/10.1148/ryai.2020200029>
- [11] J. Eng, "Sample size estimation: How many individuals should be studied?" *Radiology*, vol. 227, no. 2, pp. 309–313, 2003, PMID: 12732691. [Online]. Available: <https://doi.org/10.1148/radiol.2272012051>